

Les statistiques

Leçon 1 : vocabulaire, regroupement en classes et caractéristiques de position · Leçon 2 : caractéristiques de dispersion, variance et écart-type · Leçon 3 : organisation et représentation des données

L'ESSENTIEL

Leçon 1 : Vocabulaire, classes et caractéristiques de position

- La **population** est l'ensemble étudié ; chacun de ses éléments est un **individu**. Le **caractère** est ce que l'on observe sur chaque individu.
- Il est **qualitatif** s'il ne se mesure pas par un nombre (couleur, sexe, filière) : on compte des effectifs, on ne calcule **aucune moyenne**.
- Il est **quantitatif** s'il se mesure par un nombre : **discret** si ses valeurs sont isolées (nombre d'enfants, note), **continu** s'il prend toute valeur d'un intervalle (masse, durée) et se regroupe alors en classes.

Effectif et fréquence

L'**effectif** n_i d'une valeur ou d'une classe est le nombre d'individus qui la possèdent ; l'**effectif total** est $N = \sum n_i$.

FREQUENCE DE LA VALEUR x_i

$$f_i = \frac{n_i}{N} \quad \sum f_i = 1 = 100\%$$

L'effectif est un **entier**, la fréquence une **proportion** de $[0 ; 1]$: seules les fréquences se comparent d'une population à l'autre.

Regroupement en classes

Un caractère continu se répartit en **classes** $[a ; b[$, borne a incluse, borne b rejetée dans la classe suivante.

AMPLITUDE ET CENTRE DE LA CLASSE $[a ; b[$

$$\text{amplitude} = b - a \quad \text{centre } c = \frac{a + b}{2}$$

Le centre **remplace toutes les valeurs** de sa classe : la moyenne d'une série groupée est **approchée**.

Effectifs et fréquences cumulés

- Cumul croissant** : nombre d'individus de valeur **inférieure ou égale** ; on cumule de haut en bas, il se lit « **au plus** », le **dernier** vaut N .
- Cumul décroissant** : valeur **supérieure ou égale** ; on cumule de bas en haut, il se lit « **au moins** », le **premier** vaut N . Divisés par N , les cumuls donnent les **fréquences cumulées**.

Mode et moyenne

- Le **mode** est la valeur de **plus grand effectif** : une valeur du caractère, jamais un effectif. Plusieurs modes : série **bimodale** ou plurimodale. Série groupée : **classe modale**, la classe de plus grand effectif.

MOYENNE : x_i VALEUR OU CENTRE DE LA CLASSE i

$$\bar{x} = \frac{\sum n_i x_i}{N}$$

La moyenne est le **point d'équilibre** : la somme des écarts à la moyenne, avec leur signe, est **nulle**. Elle est **sensible aux valeurs extrêmes**.

Médiane

La **médiane** M_e partage la série **ordonnée** en deux moitiés de même effectif.

- Série discrète**, rangée par ordre croissant : si N est **impair**, M_e est la valeur de rang $\frac{N+1}{2}$; si N est **pair**, la demi-somme des valeurs de rangs $\frac{N}{2}$ et $\frac{N}{2} + 1$.
- Série groupée** : la **classe médiane** est la **première** dont le cumul croissant atteint $\frac{N}{2}$; on précise M_e par interpolation linéaire (Leçon 3).

- Position de **rang**, non de valeur : la médiane est **robuste**, là où la moyenne se déplace.

Leçon 2 : Dispersion : variance et écart-type

ÉTENDUE ET ECART MOYEN

$$e = x_{\max} - x_{\min}$$

$$e_m = \frac{\sum n_i |x_i - \bar{x}|}{N}$$

L'**étendue** ne regarde que **deux individus** : une seule valeur aberrante peut la doubler. L'**écart moyen**, dans l'unité des données, mesure l'éloignement moyen à la moyenne ; la **valeur absolue** empêche les écarts de se compenser.

Variance et écart-type

DEFINITION : MOYENNE DES CARRÉS DES ECARTS

$$V = \frac{\sum n_i (x_i - \bar{x})^2}{N} \quad \sigma = \sqrt{V}$$

- $V \geq 0$ et $\sigma \geq 0$ **toujours** (moyenne de carrés) ; $V = 0$ **si et seulement si toutes** les valeurs sont égales à la moyenne.
- V est dans l'unité des données **au carré**, σ dans l'**unité des données** : on **calcule avec V** , on **interprète avec σ** .
- Plus σ est petit, plus la série est **resserrée** : σ est la **largeur du nuage** autour de son centre.

FORMULE SIMPLIFIÉE, DITE FORMULE DE KOENIG

$$V = \frac{\sum n_i x_i^2}{N} - \bar{x}^2$$

« **Moyenne des carrés moins carré de la moyenne** » : c'est cette forme que l'on utilise, un **seul** passage sur le tableau suffisant. **Réflexe** : colonnes x_i , n_i , $n_i x_i$, $n_i x_i^2$, puis moyenne, V , σ . **Contrôles** : la moyenne tombe **entre** la plus petite et la plus grande valeur, $V \geq 0$, σ vaut en général du quart à la moitié de l'étendue ; garder la moyenne avec **toutes ses décimales** et n'arrondir qu'à la fin.

Notation $\sum_{i=1}^p n_i x_i = n_1 x_1 + \dots + n_p x_p$, où i est un **indice muet**.

Règles : $\sum (a_i + b_i) = \sum a_i + \sum b_i$ et $\sum k a_i = k \sum a_i$.

Modifier toutes les valeurs

Transformation	Moyenne	Ecart-type
ajouter k à toutes	$\bar{x} + k$	σ inchangé
multiplier par $a > 0$	$a\bar{x}$	$a\sigma$ (et V par a^2)

Ajouter k fait **glisser** le nuage, les distances ne changent pas ; multiplier par a **dilate** l'axe.

MOYENNE DE DEUX GROUPES REUNIS

$$\bar{\bar{x}} = \frac{n_1 \bar{x}_1 + n_2 \bar{x}_2}{n_1 + n_2}$$

Elle est comprise **entre** les deux moyennes, sans être leur demi-somme, sauf si les effectifs sont égaux. Aucune règle analogue pour les écarts-types.

Quartiles et écart interquartile

- Série rangée par ordre croissant : **Q_1** est la **plus petite valeur** telle qu'au moins **25 %** des données lui soient inférieures ou égales, **Q_3** celle pour **75 %** ; la médiane est le **deuxième quartile**.
- L'**écart interquartile** $Q_3 - Q_1$ est la largeur de la **moitié centrale** ; ne dépendant que de rangs, il est **robuste** et complète l'écart-type.
- Diagramme en boîte** : boîte de Q_1 à Q_3 , trait sur la médiane, moustaches jusqu'au minimum et au maximum.

Leçon 3 : Organisation et représentation des données

Caractère ou question	Représentation
qualitatif ou quantitatif discret	diagramme en bâtons (bâtons séparés , hauteur n_i ou f_i) ou diagramme circulaire
quantitatif continu groupé en classes	histogramme (rectangles accollés)
« combien au plus », « au moins »	courbe (ou polygone) des effectifs cumulés

Histogramme

C'est l'**aire** de chaque rectangle qui est proportionnelle à l'effectif de la classe.

HAUTEUR DES RECTANGLES

classes de **même amplitude** : hauteur = n_i (ou f_i)
amplitudes **différentes** : hauteur = $d_i = \frac{n_i}{\text{amplitude}}$

L'oeil compare des **surfaces** : à effectif 30 et largeurs 5 et 10, les **densités** 6 et 3 donnent des rectangles de même aire.

Polygone des effectifs

On relie les **milieux des sommets supérieurs** des rectangles, points (centre de classe ; effectif), et l'on **ferme** sur l'axe par deux classes fictives de **même amplitude** et d'**effectif nul** : son aire égale celle de l'histogramme.

Diagramme circulaire

ANGLE DU SECTEUR DE LA VALEUR OU CLASSE i

$$\text{angle}_i = f_i \times 360^\circ = \frac{n_i}{N} \times 360^\circ$$

Le disque représente l'**effectif total** ; contrôle : la somme des angles vaut **360°**. Il montre des **parts d'un tout**, mais devient illisible au-delà de sept secteurs.

Courbe des effectifs cumulés

- En abscisse les **bornes**, en ordonnée les **cumuls croissants**, reliés par des segments : ligne **montante** de 0 à N . Un cumul se rapporte à la **borne supérieure** de sa classe, jamais à son centre ; ne pas oublier le point (première borne ; 0).
- Lectures : la **médiane** est l'abscisse du point d'ordonnée $\frac{N}{2}$; de même Q_1 à $\frac{N}{4}$ et Q_3 à $\frac{3N}{4}$.
- Avec les cumuls **décroissants**, la ligne est **descendante** ; les deux lignes se coupent à l'ordonnée $\frac{N}{2}$, donc à l'abscisse de la médiane.

Interpolation linéaire

Les individus sont supposés **régulièrement répartis** dans chaque classe. Dans $[a ; b[$ d'effectif n , dont le cumul passe de C_a à $C_b = C_a + n$:

INTERPOLATION DANS LA CLASSE $[a ; b[$

$$x = a + \frac{C - C_a}{n} \times (b - a)$$

$$C = C_a + \frac{x - a}{b - a} \times n$$

La **première** donne médiane (avec $C = \frac{N}{2}$) et quartiles ; la **seconde**, le pourcentage d'individus sous un seuil. Une lecture graphique reste **approchée** : on la confirme par ce calcul.

PIEGES ET ERREURS FREQUENTES

X Pour 2 ; 4 ; 6 : moyenne = $\frac{2+4+6}{2} = 6$ • 40 élèves à 12 et 10 élèves à 16 donnent 14

✓ On divise **toujours par l'effectif total** : $\frac{2+4+6}{3} = 4$. La moyenne de deux groupes est **pondérée** : $\frac{40 \times 12 + 10 \times 16}{50} = 12,8$, non 14 ; demi-somme seulement si les effectifs sont égaux.

X Le centre de [10 ; 20[est 10 • celui de [45 ; 50[est 45

✓ Une **borne n'est pas un centre** : $\frac{a+b}{2}$ donne 15 et 47,5. Cette erreur fausse d'un coup moyenne, variance et écart-type.

X « La fréquence est 17 » • la valeur 4 apparaît 8 fois, donc le mode est 8

✓ L'effectif est un **entier**, la fréquence une **proportion** de [0 ; 1] ou un pourcentage. Le mode est la **valeur** 4, pas son effectif ; de même la classe modale est une **classe**.

X Avec $\bar{x} = 8$ et $\frac{\sum n_i x_i^2}{N} = 90$: $V = 90 - 8^2 = 82$ • $V = -9$ donne $\sigma = \sqrt{-9}$

✓ On soustrait le **carré de la moyenne** : $V = 90 - 8^2 = 26$. Une variance est une **moyenne de carrés** : $V \geq 0$ toujours, donc $V = -9$ signale une faute dans $\sum n_i x_i^2$ ou dans la moyenne.

X J'arrondis $\bar{x} = 50,2$ à 50 avant de calculer V • « la dispersion vaut $V = 24,21$ kg »

✓ Les deux termes de la soustraction sont de **grands nombres très proches** : arrondir la moyenne détruit la précision de V . Et V est en kg^2 : on interprète avec σ , dans l'unité des données.

X Classes [1 ; 2[, [2 ; 3[, [3 ; 5[d'effectifs 34, 75, 31 : rectangles de hauteurs 34, 75 et 31 • je lis la médiane sur les effectifs **simples**, aux **centres de classes**

✓ La dernière classe est **deux fois plus large** : à hauteur 31 elle paraît deux fois trop peuplée. Amplitudes inégales : hauteur = **densité**, soit 34, 75 puis $\frac{31}{2} = 15,5$. Et la médiane se lit sur les effectifs **cumulés**, portés aux **bornes supérieures** ; cette courbe est toujours **croissante**.

A SAVOIR PAR COEUR AVANT LE DEVOIR

- Fréquence** $f_i = \frac{n_i}{N}$, $\sum f_i = 1$: effectif entier, fréquence proportion.
Cumul croissant = « au plus », décroissant = « au moins ».
- Classe** $[a ; b[$: amplitude $b - a$, centre $\frac{a+b}{2}$, qui remplace la classe : moyenne groupée **approchée**.
- Moyenne** $\bar{x} = \frac{\sum n_i x_i}{N}$ (**sensible aux extrêmes**) ; **mode** = valeur ou classe de plus grand effectif ; **médiane** = rang du milieu, lue sur les cumulés à $\frac{N}{2}$ (**robuste**).
- Dispersion** : $e = x_{\max} - x_{\min}$; $e_m = \frac{\sum n_i |x_i - \bar{x}|}{N}$; écart interquartile $Q_3 - Q_1$, robuste.

- Variance** $V = \frac{\sum n_i (x_i - \bar{x})^2}{N} = \frac{\sum n_i x_i^2}{N} - \bar{x}^2$ (Koenig) ; **écart-type** $\sigma = \sqrt{V}$.
 $V \geq 0$, nulle seulement si toutes les valeurs sont égales.
- Transformations** : $+k$ donne $\bar{x} + k$ et σ inchangé ; $\times a$ ($a > 0$) donne $a\bar{x}$, $a\sigma$, $a^2 V$. Deux groupes : $\frac{n_1 x_1 + n_2 x_2}{n_1 + n_2}$.
- Représentations** : bâtons séparés (discret) ; histogramme accolé, **aires** proportionnelles, hauteur = **densité** si les amplitudes diffèrent ; circulaire, angle $f_i \times 360^\circ$; courbe cumulée sur les **bornes**, médiane par **interpolation linéaire**.