

L'ESSENTIEL

Leçon 1 : Nuage de points et point moyen

Etudier une **série statistique double** (ou à deux variables), c'est relever **simultanément** sur n individus deux caractères numériques x et y . Chaque individu i fournit un **couple** $(x_i; y_i)$; la série est la liste de ces n couples.

Nuage de points. Dans un repère du plan, on associe à chaque couple le point $M_i(x_i; y_i)$; l'ensemble des points $M_1, M_2, \dots, M_n$ est le **nuage de points** de la série.

C'est l'**appariement** des deux mesures sur un même individu qui porte toute l'information : permuter les valeurs de y entre elles change la série, même si les valeurs de x et celles de y restent les mêmes.

Tableau à double entrée

Quand plusieurs individus fournissent le **même** couple, on range la série dans un **tableau à double entrée** : valeurs de x en lignes, valeurs de y en colonnes, et dans chaque case l'**effectif** n_{ij} du couple $(x_i; y_j)$.

- **Distributions marginales** : les totaux des lignes et des colonnes, portés en **marge**. Chacune est une série à **une** variable, celle qu'on obtiendrait en oubliant l'autre caractère.
- **Fréquence marginale** = $\frac{\text{effectif marginal}}{n}$, comprise entre 0 et 1; la somme des fréquences marginales de x vaut 1, et de même pour y .
- **Contrôle** : le total général doit se retrouver en additionnant les marges **dans les deux sens**.

Point moyen

POINT MOYEN DU NUAGE

$$G(\bar{x}; \bar{y}) \quad \bar{x} = \frac{1}{n} \sum x_i \quad \bar{y} = \frac{1}{n} \sum y_i$$

$$\text{pondéré : } \bar{x} = \frac{1}{n} \sum n_i x_i \quad \bar{y} = \frac{1}{n} \sum n_i y_i \quad \text{avec } n = \sum n_i$$

Données en classes : on remplace chaque classe par son **centre**, demi-somme de ses deux bornes, puis on applique la formule pondérée.

G est le **résumé du nuage en un seul point** : $\sum(x_i - \bar{x}) = 0$ et $\sum(y_i - \bar{y}) = 0$, le nuage s'équilibre autour de lui dans les deux directions. **Toutes les droites d'ajustement du chapitre passent par G .**

Construire le nuage

- En **abscisse** la variable qui **explique** (temps, dose, surface, prix), en **ordonnée** celle que l'on veut **prévoir** (rendement, effectif, quantité vendue).
- Echelles choisies sur les valeurs extrêmes, **indépendantes** d'un axe à l'autre; unité indiquée sur chaque axe; toute coupure d'axe est signalée.
- Un point net par couple : on ne **relie jamais** les points, un nuage n'est pas une courbe.
- G se place avec un **symbole différent** et doit tomber au milieu du nuage; s'il en est très loin, une moyenne est faussée.

Leçon 2 : Covariance, corrélation et méthode de Mayer

COVARIANCE : DEFINITION ET FORMULE DE CALCUL

$$\text{cov}(x, y) = \sigma_{xy} = \frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y})$$

$$\text{cov}(x, y) = \frac{1}{n} \sum x_i y_i - \bar{x} \bar{y}$$

Cas pondéré : $\text{cov}(x, y) = \frac{1}{n} \sum n_{ij} x_i y_j - \bar{x} \bar{y}$.

Signe : covariance **positive** → tendance **montante**; **négative** → tendance **descendante**; **nulle** → aucune tendance linéaire.

C'est la formule de Koenig transposée : « moyenne des produits moins produit des moyennes ». Pour $y = x$, elle redonne $\text{cov}(x, x) = V(x)$: **la variance est le cas particulier de la covariance où les deux variables sont confondues.**

Coefficient de corrélation linéaire

COEFFICIENT DE CORRELATION LINEAIRE

$$r = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y} \quad \sigma_x = \sqrt{V(x)} \quad \sigma_y = \sqrt{V(y)}$$

$$-1 \leq r \leq 1 \quad r \text{ sans unité, du signe de la covariance}$$

$$\text{Avec } V(x) = \frac{1}{n} \sum x_i^2 - \bar{x}^2 \text{ et } V(y) = \frac{1}{n} \sum y_i^2 - \bar{y}^2.$$

$ r $	Lecture
$ r = 1$	points exactement alignés ; ajustement affine parfait
$ r \geq 0,9$ environ	forte corrélation; ajustement affine justifié
$ r \approx 0,5$	corrélation moyenne ; ajustement grossier
$ r $ proche de 0	aucun lien linéaire ; ne pas tracer de droite

Le **signe** de r donne le sens, sa **valeur absolue** la force. $r = 0$ signifie « aucun lien **linéaire** » et non « aucun lien » : des points situés sur une parabole peuvent donner $r = 0$.

Corrélation n'est pas causalité. Un r proche de 1 prouve que les deux grandeurs ont varié ensemble, jamais que l'une est la cause de l'autre : le lien peut être inversé, ou dû à une **troisième** grandeur cachée agissant sur les deux.

Ajustements graphiques

Au jugé. Si le nuage est allongé, on trace **à la règle** une droite qui suit la tendance, en laissant à peu près autant de points au-dessus qu'en dessous. Rapide et sans calcul, mais deux élèves ne tracent pas la même droite.

Au jugé par G . On impose à la droite de passer par le **point moyen**; un second point la détermine entièrement, et son équation s'obtient par la méthode des deux points.

METHODE DE MAYER : DROITE DES POINTS MOYENS

couples rangés par x croissant, partagés en **deux groupes de même effectif**

$$G_1(x_1; y_1), G_2(x_2; y_2) \rightarrow \text{droite } (G_1 G_2) : y = ax + b$$

$$a = \frac{y_2 - y_1}{x_2 - x_1} \quad b = y_1 - ax_1$$

Si n est **impair**, le **premier** groupe reçoit le point supplémentaire. La droite de Mayer passe toujours par le point moyen G du nuage entier; à effectifs égaux, G est le **milieu** de $[G_1 G_2]$, ce qui fournit la vérification.

Conduite du calcul

- Tableau à cinq colonnes : $x_i, y_i, x_i^2, y_i^2, x_i y_i$, puis somme de chaque colonne.
- En déduire $\bar{x}$ et $\bar{y}$, puis $\text{cov}(x, y), V(x), V(y), \sigma_x, \sigma_y$ et enfin r .
- **Contrôles** : le signe de la covariance suit l'allure du nuage; les deux variances sont positives; r appartient à $[-1; 1]$.
- **Interpréter** en une phrase : le signe donne le sens, la valeur absolue la force, et l'on précise si un ajustement affine est justifié.

Leçon 3 : Ajustement par les moindres carrés

Parmi toutes les droites $y = ax + b$, il en existe **une et une seule** qui rend **minimale** la somme des carrés des écarts **verticaux** $\sum (y_i - (ax_i + b))^2$: c'est la **droite de régression de y en x** , ou droite des moindres carrés.

DROITE DE REGRESSION DE y EN x

$$y = ax + b \quad a = \frac{\text{cov}(x, y)}{V(x)} = \frac{\sigma_{xy}}{\sigma_x^2} \quad b = \bar{y} - a\bar{x}$$

Elle **passer par le point moyen** $G(\bar{x}; \bar{y})$: la formule de b n'est que l'égalité $y = ax + b$ résolue en b . Au dénominateur de la pente figure la **variance de la variable de départ** ; a a donc le signe de la covariance, donc celui de r . Les écarts $e_i = y_i - (ax_i + b)$ ont une somme nulle, et aucune autre droite ne rend $\sum e_i^2$ plus petite.

Droite de régression de x en y

Lorsque c'est x que l'on veut prévoir à partir de y , on échange les rôles des deux variables et l'on minimise les écarts **horizontaux**.

REGRESSION DE x EN y ET RELATION ENTRE LES DEUX DROITES

$$x = a'y + b' \quad a' = \frac{\text{cov}(x, y)}{V(y)} \quad b' = \bar{x} - a'\bar{y} \\ a \times a' = r^2$$

Elle passe aussi par G : les deux droites se coupent **toujours** au point moyen. Comme $r^2 \leq 1$, elles sont en général **distinctes**, et

confondues si et seulement si $r^2 = 1$, c'est-à-dire lorsque les points sont exactement alignés. Elles ne minimisent pas la même chose : plus $|r|$ est proche de 1, plus l'angle qu'elles forment est petit.

Prévision

Pour prévoir la valeur de y associée à x_0 , on remplace x par x_0 dans l'équation : $y_0 = ax_0 + b$. Le résultat se donne **avec son unité** et doit être plausible dans le contexte.

- **Interpolation** : x_0 à l'**intérieur** de l'intervalle des données observées → prévision raisonnablement fiable.
- **Extrapolation** : x_0 **hors** de cet intervalle → fiabilité qui décroît vite, à commenter : rien ne garantit que la relation reste affine, et une production finit par plafonner alors qu'une droite monte indéfiniment.

Marche à suivre. Tableau de calcul $(x_i, y_i, x_i^2, x_i y_i) \rightarrow \bar{x}$ et $\bar{y} \rightarrow \text{cov}(x, y)$ et $V(x) \rightarrow a$ puis $b \rightarrow$ **vérifier** que $a\bar{x} + b$ redonne $\bar{y}$. Pour tracer, deux points suffisent : G et un point d'abscisse extrême. Calculer **r avant** d'ajuster : si $|r|$ est faible, les formules donnent quand même un a et un b , mais la droite ne décrit rien.

PIEGES ET ERREURS FREQUENTES

X $r = 0,9$ donc x cause y

✓ La corrélation mesure un lien **linéaire**, jamais une **cause**. Le lien peut être inversé, ou provenir d'une **troisième** variable cachée qui agit sur les deux. La statistique constate, elle ne démontre pas les causes.

X $r = 0$ donc x et y n'ont aucun lien

✓ $r = 0$ signifie seulement qu'il n'y a pas de lien **linéaire**. Des points situés sur une parabole peuvent donner $r = 0$ tout en étant liés par une relation exacte.

X $r = 1,4$: la corrélation est très forte

✓ Impossible : on a **toujours** $-1 \leq r \leq 1$. Une valeur hors de $[-1; 1]$ signale une erreur de calcul, le plus souvent un écart-type oublié au dénominateur.

X $a = \frac{V(x)}{\text{cov}(x, y)}$: la droite de y en x et celle de x en y sont la même

✓ Les deux termes sont inversés : $a = \frac{\text{cov}(x, y)}{V(x)}$. Au dénominateur figure toujours la **variance de la variable de départ** : $V(x)$ pour $y = ax + b$, $V(y)$ pour $x = a'y + b'$. Les deux droites sont **distinctes** sauf si $|r| = 1$; elles se coupent en G .

X Le point moyen G est le point du nuage le plus haut

✓ $G(\bar{x}; \bar{y})$ a pour coordonnées les deux **moyennes** : ce n'est en général **pas** un point du nuage. Toutes les valeurs entrent dans les moyennes, y compris celles qui contredisent la tendance.

X Dans le tableau à double entrée, la fréquence marginale de $x = 2$ est 6

✓ 6 est l'**effectif** marginal ; la **fréquence** marginale est $\frac{6}{n}$, soit $\frac{6}{10} = 0,6$ pour $n = 10$. Avec un tel tableau, les moyennes se calculent **pondérées** par les effectifs.

X L'année 2026 donne $x = 2026$ dans la droite $y = 13x + 81$

✓ x est le **rang** de l'année, tel qu'il a été défini dans l'énoncé : si 2020 correspond à $x = 1$, alors 2026 correspond à $x = 7$.

X $|r| = 0,2$, mais on trace la droite d'ajustement et l'on prévoit à 20 ans

✓ Un calcul ne refuse jamais de s'exécuter : la droite existe mais ne décrit rien. On calcule **r avant** d'ajuster. Et prévoir loin des données est une **extrapolation** : sa fiabilité décroît vite, elle doit être commentée.

A SAVOIR PAR COEUR AVANT LE DEVOIR

- 1 Série double = liste de **couples** $(x_i; y_i)$; nuage = points $M_i(x_i; y_i)$, jamais reliés. Tableau à double entrée : les **marges** donnent les distributions marginales, et fréquence marginale = $\frac{\text{effectif marginal}}{n}$.
- 2 $G(\bar{x}; \bar{y})$ avec $\bar{x} = \frac{1}{n} \sum x_i$; moyennes **pondérées** s'il y a des effectifs, **centres** des classes si les données sont groupées. **Toute droite d'ajustement passe par G .**
- 3 $\text{cov}(x, y) = \sigma_{xy} = \frac{1}{n} \sum x_i y_i - \bar{x} \bar{y}$, du signe de la tendance ; $\text{cov}(x, x) = V(x) = \frac{1}{n} \sum x_i^2 - \bar{x}^2$.
- 4 $r = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y} \in [-1; 1]$: le **signe** donne le sens, la **valeur absolue** la force. $|r| = 1$: points alignés ; $|r| \geq 0,9$: ajustement affine justifié ; $r = 0$: pas de lien **linéaire**.

- 5 **Mayer** : ranger par x croissant, deux groupes de même effectif (le premier reçoit le point en trop si n est impair), droite $(G_1 G_2)$ avec $a = \frac{y_2 - y_1}{x_2 - x_1}$ et $b = y_1 - ax_1$; elle passe par G .
- 6 **Régression de y en x** : $a = \frac{\text{cov}(x, y)}{V(x)}$, $b = \bar{y} - a\bar{x}$; elle rend minimale $\sum (y_i - (ax_i + b))^2$ et passe par G .
- 7 **Régression de x en y** : $a' = \frac{\text{cov}(x, y)}{V(y)}$, $b' = \bar{x} - a'\bar{y}$, avec $a \times a' = r^2$: droites **distinctes** sauf si $|r| = 1$, sécantes en G . Au dénominateur, la **variance de la variable de départ**.
- 8 **Prévision** : remplacer x par x_0 dans $y = ax + b$, avec l'unité. **Interpolation** fiable, **extrapolation** à commenter. Corrélation n'est pas causalité, et l'on calcule **r avant** d'ajuster.